

刘峰

19252153207 · distilledw@sjtu.edu.cn
AI Infra · GPU 算子优化 · 大模型推理加速 · 异构计算



教育背景

上海交通大学	计算机科学与技术·硕士	2024.09–2027.03
中国人民解放军国防科技大学	计算机体系结构·本科	2020.09–2024.06

实习经历

阿里控股平台技术 TRE AI Infra 实习生 B300 / PPU1.5 大模型推理与算子优化	2026.05–2026.08 CUDA / PTX / Tensor Core / Nsight Compute
B300 微架构实测与性能归因 实测指令延迟/吞吐、存储层级布局与带宽、tcgen05.mma 计算周期，沉淀 2209 格实测数据、144 个 opcode、184 个 mapping 与 32 个 finding 族；自研 ncu profile 瓶颈分流工具，将单 kernel 反馈从约 100KB 压缩至 2KB。 Fused MoE Prefill 结合实测微架构特性以 CUDA 重写并融合计算与访存，在线上 workload 中较 TensorRT-LLM 版本加速 1.2×。 Kernel Agent 自动优化 Workflow 将专家优化过程拆分为依赖分解、映射、流水排布、结构搜索、生成实测五阶段，以 roofline、流水模型和真机 ncu 三口径区分结构与实现瓶颈；无人干预 32 小时优化 B300 FA4，24 组 shape 中 ≥4.5K 全面反超 cuDNN，多数加速 1.1–1.34×。 PPU1.5 · 128K Prefill 推理栈 面向真实 shape 分布，分层接入 FA、GDR、MXFP4 MoE、Shared Expert MLP 与 CausalConv1D，单算子最高加速 3.01×；经同进程 A/B 与模型级正确性验证，累计将 TTFT 从 13.4105s 降至 11.1982s (−16.50%，1.198×)。 PPU1.5 · 128K Decode 推理栈 优化 Attention、GDR、MLP 等 9 条算子路径，并接入自研 CUDA Mega MoE；EP8 / MTP 主形状 T=4 单算子由 321.34μs 降至 134.62μs (2.387×)；同等预热条件下模型稳态单步由 28.2845ms 降至 25.439ms (1.112×)，冷态加速 1.149×；128K 正确性 9/9、32 并发 32/32 通过。	

科研经历

StreamGrid · 流式点云分析加速 挑战 点云 kNN 等不规则算子具有全局数据依赖与动态搜索路径，难以形成片上流水，频繁访问 DRAM 导致内存墙。 方法 局部性分块：利用 kd-tree 的空间局部性将全局搜索约束到局部子树，并以延迟阈值将变长搜索规整为定长数据流；设计结合 Line Buffer 的全流水架构，通过 ILP 求解最小片上 SRAM 配置。 结果 片上 SRAM 面积降低 61.3%、能耗降低 40.5%，精度损失低于 1%；相比 PointAcc 等 5 款 SOTA 加速器，端到端加速 10.0×、能效提升 3.9×。	ASPLOS 2025 · 共一
Nebula · 城市级 3DGS VR 协同渲染 挑战 城市级 3DGS 渲染需要 66GB 显存，远超 VR 端侧 12GB 容量；云端全量渲染并回传视频流的带宽需求超过 1Gbps@4K90FPS。 方法 提出端云协同渲染架构：云端执行 LoD 搜索、端侧完成渲染；利用连续帧间高达 99% 的高斯重叠，仅传输帧间增量高斯点；设计基于 LUT 的快速指数单元，缓解端侧算力瓶颈。 结果 传输带宽降低 19.25×，云端搜索加速 52.7×，系统端到端加速 12.1×、能效提升 14.9×；实现城市级 VR 90FPS 渲染，质量损失低于 0.1dB。	ASPLOS 2026 · 共一
Deltoris · 实时 VLA 推理加速 挑战 扩散式 VLA（视觉—语言—动作）模型计算稠密，在 50–200Hz 高频控制场景下面临严格的端侧延迟与能耗约束。 方法 利用相邻帧高达 96% 的相似性进行比特级差分，将稠密矩阵转化为稀疏计算；以蒸馏小模型生成多步候选动作并由大模型批量验证，将逐帧串行推理转为批量并行；设计结合 Bit-Slicing 的 1-D PE 阵列跳过零比特计算。 结果 相比 Orin AGX GPU 加速 34.87×，推理帧率由 2.01 提升至 70.09 FPS；相比最快的已有加速器提升 5.8×，任务成功率损失低于 1%。	MICRO 2026 · 第一

专业技能与荣誉

GPU 与算子 CUDA, PTX 实测, Tensor Core, ncu profiling, 算子开发与融合, GPU/国产卡跨平台移植

编程与架构 C/C++, Python, Shell, PyTorch; 加速器设计与设计空间探索, ILP 建模

工程与英语 Linux (Ubuntu), Git, Conda/Docker; CET-6, 无障碍阅读英文文献

奖励荣誉 上海交通大学2026年硕士生国家奖学金

CCF CSP 认证 300 分 (2023), 美国大学生数学建模竞赛S 奖 (2022), 蓝桥杯省赛三等奖 (2021)